## Méthodes empiriques et langages de script Projet: Sentiment analysis in Twitter

Paola Merlo, Yves Scherrer 2015–2016

## **Données**

Nous vous mettons à disposition les données suivantes:

- **training.txt** Le fichier à utiliser pour l'entraînement du classifieur. Pour la première étape (baseline), vous n'aurez normalement pas besoin de ce fichier.
- **development.input.txt** Vous allez donner ce fichier comme entrée à votre script (baseline ou classifieur). Notez que la troisième colonne vaut toujours "unknwn", et la tâche de votre script est de créer un fichier du même format (que vous pouvez appeler p.ex. *development.prediction.txt*) mais en remplaçant "unknwn" par l'une des trois valeurs "positive", "negative", "neutral".
- **development.gold.txt** Ce fichier contient les mêmes données que *development.input.txt* mais avec les réponses correctes. Il vous servira pour l'évaluation de votre méthode à l'aide du script ci-dessous.
- scoredev.py Un script pour évaluer vos résultats. Exécutez-le comme suit:
  python3 scoredev.py b development.prediction.txt development.gold.txt
- test.input.txt Lorsque vous avez obtenu des résultats satisfaisants avec les données développement (ou que le deadline approche...), vous devez donner ce fichier comme entrée à votre script. Le script devra alors créer un fichier du même format (que vous pouvez appeler p.ex. test.prediction.txt) mais en remplaçant "unknwn" par l'une des trois valeurs "positive", "negative", "neutral".

Vous devez m'envoyer ce fichier par e-mail ou par Chamilo pour l'évaluation, car nous ne mettons pas à disposition les réponses correctes du fichier test pour suivre le protocole de la Shared Task au plus près. Vous allez recevoir en retour les scores (précision, rappel, F-mesure, exactitude) par type de données (tweets normaux vs. tweets sarcastiques).<sup>1</sup>

<sup>&</sup>lt;sup>1</sup>Les tweets sarcastiques sont ceux dont l'identifiant de la deuxième colonne commence par TS, mais cela ne

devrait pas avoir d'importance pour les deux premières étapes du projet.
2